Superstore Sales - توثيق تنظيف الداتا

في المهمة الأولى اشتغلت على داتا Superstore Sales (18 عمود) باستخدام Power Query في Power BI. الهدف كان إني أنضف الداتا وأجهزها للتحليل، وده شرح اللي عملته خطوة بخطوة.

اللي عملته في التنظيف

1. فحص جودة الداتا: فعّلت Column Quality و Column Distribution وبصيت على كل عمود. كل الأعمدة مفيهاش Errors، وعمود Sales بس هو اللي فيه قيم فاضية (null).

2. القيم الفاضية في Sales: لقيت 6 صفوف بس، وكلهم لنفس المنتج (TEC-AC-10004659 - Imation Secure+ USB Flash Drive). يعني المنتج ده مفيهوش ولا سعر في الداتا، فمقدرتش أعوّض من صفوفه التانية. بدل ما أحذف الصفوف، عوّضتها بالوسيط (Median) لمبيعات الـ Sub-Category بتاعه وهو Accessories، والقيمة طلعت 99.99. استخدمت الوسيط مش المتوسط عشان المتوسط بيتأثر بالمنتجات الغالية. القيمة دي تقديرية وأنا واعي بكده.

3. أنواع البيانات: حوّلت Postal Code من رقم لـ Text، لأنه كود مش قيمة أجمع عليها، وكمان عشان لو في كود بيبدأ بصفر الصفر ميضيعش. وتأكدت إن Sales نوعه Fixed decimal number وإن Order Date و Ship Date نوعهم Date.

4. تنضيف النصوص: طبقت Trim و Clean على الأعمدة النصية زي Customer Name و City و State و Product Name عشان أشيل أي مسافات زيادة أو حروف مخفية، ومتتعدش نفس القيمة مرتين.

الأعمدة اللي ضفتها

- Shipping Days: عدد الأيام بين Order Date و Ship Date، وتأكدت إنه مفيش قيم سالبة.

- Year و Month و Month Name و Quarter: طلعتهم من Order Date عشان أقدر أحلل المبيعات على مدار الزمن.

- بعد كده سميت الاستعلام Superstore_Clean وعملت Close & Apply.

ملاحظات للي هيكمل

- الداتا مفيهاش Profit ولا Quantity ولا Discount، فالتحليل هيكون على Sales بس.

- القيمة 99.99 اللي عوّضت بيها الـ 6 صفوف تقديرية، ولو في مصدر للسعر الحقيقي للمنتج يتحدّث.

المرحلة الثانية: تصميم البيانات وتحليلها

استكمالًا لتوثيق المهمة الأولى، يتناول هذا الجزء فهم مجموعة البيانات، وإعداد قاموس البيانات، وفحص البيانات ومشكلاتها، وتحديد خطوات التنظيف، وشرح تصميم الجدول وتحليل النظام.

١- فهم مجموعة البيانات

• اسم مجموعة البيانات: بيانات مبيعات المتجر.

• حجم الملف الأصلي المرفق: 9,800 سجلًا و18 عمودًا.

• الغرض من البيانات هو تحليل المبيعات وفقًا للوقت والعملاء والمنتجات والمواقع وطرق الشحن.

• كل صف يمثل بندًا لمنتج ضمن طلب، وقد يتكرر رقم الطلب في أكثر من صف إذا احتوى الطلب على أكثر من منتج.

• يمكن استخدام البيانات لمقارنة المبيعات حسب التاريخ والمنطقة والفئة والفئة الفرعية والعميل وطريقة الشحن.

• حدود مجموعة البيانات لا تحتوي على أعمدة الربح أو الكمية أو الخصم؛ لذلك يقتصر التحليل المالي المتاح على قيمة المبيعات.

٢- قاموس البيانات

يوضح الجدول معنى كل حقل ونوع البيانات المناسب له واستخدامه في التحليل. تم الاحتفاظ بأسماء الحقول كما تظهر في ملف البيانات الأصلي حتى يسهل التعرف عليها داخل برنامج التحليل.

اسم الحقل	وصف الحقل	نوع البيانات المناسب	استخدام الحقل
Row ID	رقم السجل داخل مجموعة البيانات.	رقم صحيح	تمييز السجلات ومراجعتها.
Order ID	رقم الطلب.	نص	تجميع السجلات التي تنتمي إلى الطلب نفسه.
Order Date	تاريخ إنشاء الطلب.	تاريخ	تحليل المبيعات عبر الزمن.
Ship Date	تاريخ شحن الطلب.	تاريخ	متابعة الشحن وحساب مدته.
Ship Mode	طريقة الشحن.	نص	مقارنة المبيعات حسب طريقة الشحن.
Customer ID	المعرّف الخاص بالعميل.	نص	تمييز العملاء وتجميع تعاملاتهم.
Customer Name	اسم العميل.	نص	عرض العملاء وتحليل مشترياتهم.
Segment	شريحة العميل.	نص	مقارنة المبيعات بين شرائح العملاء.
Country	الدولة.	نص	التحليل الجغرافي حسب الدولة.
City	المدينة.	نص	التحليل الجغرافي حسب المدينة.
State	الولاية أو المنطقة الإدارية.	نص	مقارنة المبيعات حسب المنطقة الإدارية.
Postal Code	الرمز البريدي.	نص	تحديد الموقع، ولا يُستخدم في العمليات الحسابية.

Region	الإقليم الجغرافي.	نص	مقارنة المبيعات بين الأقاليم.
Product ID	المعرّف الخاص بالمنتج.	نص	تمييز المنتجات.
Category	الفئة الرئيسية للمنتج.	نص	تحليل المبيعات حسب الفئة.
Sub-Category	الفئة الفرعية للمنتج.	نص	تحليل المبيعات بتفصيل أكبر.
Product Name	اسم المنتج.	نص	عرض المنتجات ومقارنة مبيعاتها.
Sales	قيمة المبيعات المسجلة للسجل.	رقم عشري ثابت	حساب إجمالي المبيعات ومقارنتها.

٣- فحص البيانات واكتشاف المشكلات

عنصر الفحص	نتيجة الفحص في الملف الأصلي
عدد السجلات	9,800 سجلًا
عدد الأعمدة	18 عمودًا
القيم الفارغة في المبيعات	0
القيم الفارغة في الرمز البريدي	11
الصفوف المكررة بالكامل	0
تكرار رقم السجل	0

نتيجة الفحص الفعلي للملف الأصلي المرفق لا توجد قيم فارغة في عمود المبيعات، بينما توجد 11 قيمة فارغة في عمود الرمز البريدي. كما لم تظهر صفوف مكررة بالكامل، ولم يتكرر رقم السجل.

٤- تحديد خطوات تنظيف البيانات

• فحص جودة الأعمدة وتوزيع القيم لتحديد الأخطاء والقيم الفارغة.

• مراجعة القيم الفارغة في الرمز البريدي، وتحديد طريقة التعامل معها. لأنه رمز تعريفي، لا يتم تعويضه بمتوسط أو وسيط؛ ويمكن تركه فارغًا أو استخدام وصف واضح مثل «غير متوفر» وفق متطلبات المشروع.

• تحويل الرمز البريدي إلى نص للحفاظ على تنسيقه، بما في ذلك الأصفار في بداية الرمز إن وجدت.

• ضبط حقلي تاريخ الطلب وتاريخ الشحن كنوع تاريخ، وضبط المبيعات كرقم عشري ثابت.

• تنظيف الحقول النصية من المسافات الزائدة والأحرف غير المرئية.

• التحقق من عدم وجود سجلات مكررة أو أرقام سجلات مكررة.

• إنشاء مدة الشحن بطرح تاريخ الطلب من تاريخ الشحن، ثم مراجعة أي مدة سالبة.

• استخراج السنة ورقم الشهر واسم الشهر والربع السنوي من تاريخ الطلب لدعم التحليل الزمني.

• إعادة فحص جودة البيانات بعد التنظيف، ثم حفظ الجدول المنظف باسم واضح.

٥- تصميم البيانات والمخطط

الملف الأصلي المتاح يحتوي على جدول واحد فقط يضم معلومات الطلب والعميل والمنتج والموقع والشحن والمبيعات. لذلك يكون التصميم الحالي مخططًا بسيطًا بجدول واحد، ولا توجد في الملف جداول مستقلة أو علاقات فعلية بينها.

اسم الجدول المقترح بعد التنظيف: Superstore_Clean.

مكونات الجدول: Row ID، Order ID، Order Date، Ship Date، Ship Mode، Customer ID، Customer Name، Segment، Country، City، State، Postal Code، Region، Product ID، Category، Sub-Category، Product Name، Sales، بالإضافة إلى الأعمدة المحسوبة التي تم إنشاؤها في المهمة الأولى إذا كانت موجودة في النسخة المنظفة.

لا يلزم رسم مخطط علاقات متعدد الجداول في الوضع الحالي؛ لأن المصدر جدول واحد. ويمكن تمثيل التصميم الحالي بجدول واحد فقط. لا ينبغي اختراع جداول عملاء أو منتجات أو طلبات وعلاقات بينها ما دامت غير موجودة في مصدر البيانات المرفق.

المخطط الحالي	الحقول الأساسية
Superstore_Clean	بيانات الطلب + العميل + المنتج + الموقع + الشحن + المبيعات

٦- تحليل النظام وتصميمه

عنصر النظام	الوصف
هدف النظام	تنظيم بيانات المبيعات وتجهيزها للتحليل وإعداد تقارير تساعد على فهم اتجاهات المبيعات.
المدخلات	ملف بيانات المبيعات الأصلي بما يحتويه من معلومات الطلبات والعملاء والمنتجات والمواقع والشحن والمبيعات.
المعالجة	فحص جودة البيانات، ومعالجة النواقص وفق قرار موثق، وضبط أنواع البيانات، وتنظيف النصوص، وإنشاء الحقول الزمنية ومدة الشحن.
المخرجات	جدول منظم وجاهز للتحليل، وتقارير توضح المبيعات حسب الزمن والمنطقة والفئة والمنتج والعميل وطريقة الشحن.
المستخدم المستهدف	محلل البيانات أو مسؤول المبيعات الذي يحتاج إلى متابعة المبيعات ومقارنة النتائج.
الأداة المستخدمة	برنامج تحليل البيانات ومحرر الاستعلامات لتجهيز البيانات، ثم أدوات إعداد التقارير والتحليل.

تسلسل العمل: يبدأ المستخدم بتحميل ملف البيانات، ثم فحص الأعمدة والقيم، وتنفيذ خطوات التنظيف والتحويل، وبعد ذلك تحميل البيانات إلى نموذج التحليل. وفي النهاية تُستخدم الحقول المتاحة لإعداد التقارير ومقارنة المبيعات.

٧- حدود التحليل

- يمكن تحليل المبيعات حسب التاريخ والمنطقة والفئة والفئة الفرعية والعميل وطريقة الشحن.
- لا يمكن حساب الربح أو هامش الربح لعدم وجود عمود الربح.
- لا يمكن حساب عدد الوحدات المباعة لعدم وجود عمود الكمية.
- لا يمكن تحليل أثر الخصومات لعدم وجود عمود الخصم.
- القيمة 99.99 المذكورة في توثيق المهمة الأولى قيمة تقديرية، ويجب الإفصاح عن ذلك إذا كانت موجودة في النسخة التي سيتم تحليلها.

٨- خلاصة المرحلة الثانية

تم استكمال وصف مجموعة البيانات، وإعداد قاموس البيانات للأعمدة الثمانية عشر، وتوثيق نتائج فحص الملف الأصلي، وتحديد خطة تنظيف البيانات، وشرح سبب الاكتفاء بجدول واحد بدل إنشاء مخطط علاقات متعدد الجداول، بالإضافة إلى توضيح هدف النظام ومدخلاته ومعالجته ومخرجاته وحدود التحليل.